

# TEKNOFEST

## HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

### SAĞLIKTA YAPAY ZEKÂ YARIŞMASI

### ÖN TASARIM RAPORU

ETUAI

#58322

TEKNOFEST  
HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

## **İçindekiler**

### **1. Takım Şeması**

#### **1.1. Ekip organizasyonu**

### **2. Kullanılması planlanan algoritmalar ve yazılım mimarisi**

#### **2.1. Makine öğrenme modelinin geliştirilmesi ve yeniden kullanımı**

##### **2.1.1. Literatür taraması ve aday yöntemlerin belirlenmesi**

##### **2.1.2. Problemde kullanılacak veri setleri**

##### **2.1.3. Model performans testleri için gerçekleştirilecek deneysel süreçler ve kullanılacak metrikler**

#### **2.2.Yazılım Çözümü**

##### **2.2.1. Makine öğrenimi modelinin eğitim, test ve kullanım süreçlerine önerilen ait kullanım-usecase-çizeneği**

##### **2.2.2. Kullanılan teknolojileri içeren yazılım bileşen-component-çizeneği**

### **3. Kullanılması planlanan donanımlar ve özellikleri**

#### **3.1. Eğitim Donanımları**

#### **3.2.Test Donanımları**

### **4. Özgünlük**

### **5. Proje Takvimi**

### **6. Referanslar**

## 1. Takım şeması

### 1.1 Ekip organizasyonu

ETUAI takımı Türkiye’de mühendislikten sağlık ve tıp alanına birçok disiplinde yapay zekâ modelleri geliştirmek ve Türkiye’yi yapay zekâ çalışmalarında öncü ülkelerden biri durumuna getirmek amacıyla TOBB Ekonomi ve Teknoloji Üniversitesinde kurulmuştur.

Bu amacı gerçekleştirmek adına atmak istediğimiz adımlardan bir tanesi de Teknofest *Sağlıkta Yapay Zekâ* yarışması kapsamında Türkiye’nin yapay zekâ literatürüne bir yeni çalışma daha eklemek ve yarışma boyunca geliştirdiğimiz ve uyguladığımız yeni fikir ve metotlar ile tıp sektöründe kullanılabilecek güvenilir bir yapay zekâ modeli geliştirmektir. ETUAI takım şeması Şekil. 1’de paylaşılmıştır.



Şekil. 1 ETUAI takım şeması

Şekil. 1’de görülebileceği üzere ETUAI takımı bir takım kaptanı, bir takım üyesi ve bir danışmandan oluşmaktadır. Danışman Dr. Recep Muhammet Görgülüarslan’ın projedeki görevi takım üyelerine çalışmalarda yol göstermek, takım üyeleri ile kullanılması planlanan algoritma ve metotlar üzerinde tartışmak, fikir sağlamak ve genel proje akışı çerçevesinde mentorluk yapmak olarak tanımlanmıştır. Takım kaptanı Görkem Can Ateş’in görevi ise iletişim sorumluluğunun yanı sıra, literatür taraması, örnek veri setlerinin bulunması ve incelenmesi, sınıflandırma-segmentasyon modellerinin oluşturulması olarak tanımlanmıştır. Mehmet Uğur Güdelek ise benzer şekilde literatür taraması, sınıflandırma-segmentasyon modelinin geliştirilmesi ve optimizasyonu olarak tanımlanmıştır. Her iki model için elde edilen sonuçlara

göre model optimizasyonu kısmı Görkem Can Ateş ve Mehmet Uğur Güdelek tarafından beraber yürütülecektir.

## **2. Kullanılması planlanan algoritmalar ve yazılım mimarisi**

### **2.1 Makine öğrenme modelinin geliştirilmesi ve yeniden kullanımı**

#### **2.1.1 Literatür taraması ve aday yöntemlerin belirlenmesi**

Bu yarışma kapsamında tamamlanması hedeflenen görevler ilk olarak kontrast madde verilmeden elde edilen beyin Bilgisayarlı Tomografi (BT) görüntüleri kullanılarak, normal sınırlarda beyin BT'si veya inme bulguları olan beyin BT'si olduğunu tespit edecek bir derin öğrenme modeli geliştirilmesi, ikinci olarak da inmenin iskemik veya hemorajik inme olduğunun derin öğrenme metotları kullanılarak tespit edilmesi ve segmente edilmiş görüntünün oluşturulmasıdır.

İlk kısım için (normal-inme bulgulu CT) öncelik problemin tanımlanmasıdır. Bu kısımda problem ikili sınıflandırma (Binary Classification) problemidir. Sınıflandırma problemlerinde, özellikle yüksek çözünürlükteki resimler söz konusu ise, Convolutional Neural Network (CNN) kullanımı genellikle zorunluluktur. CNN yapıları içerisinde konvolüsyonel filtreler yardımıyla veriyi işler. Bu yöntemin avantajı resimlerdeki piksellerin sadece kendi değerlerinin değil, aynı zamanda birbirleri ile ilişkilerinin de önemli olması sebebiyle, konvolüsyonel filtreler ile resmin lokal olarak işlenebilmesidir. CNN mimarisinin başarısı ilk defa MNIST veri setinde kullanıldığından bu yana devam etmektedir.

CNN mimarileri yüksek performanslı eğitim için oldukça yüksek veri setlerine ihtiyaç duymaktadır (örn:ImageNet). Bu sebeple biyomedikal veri setlerinin sınıflandırma problemlerinde kullanılması, genellikle veri setlerinin az veriden oluşmasına bağlı olarak eğitim performansının düşüklüğü gibi çeşitli problemler ortaya çıkarmaktadır. Bu bağlamda veri artırılması (Data Augmentation) ve transfer learning teknikleri doğal bir çözüm sağlamaktadır.

Literatürde biyomedikal görüntüler için çeşitli derin öğrenme metotları kullanılmıştır. Örneğin beyin tümörü Manyetik Rezonans (MR) görüntüleri kullanılarak basit bir CNN mimarisi önerilmiş ve yüksek sınıflandırma doğruluk (Accuracy) değeri elde edilebilmiştir [1], [2]. Özellikle az veriden oluşan veri setleri için transfer learning ve fine-tuning tekniklerinin biyomedikal resim eğitimlerinde performansı ciddi şekilde arttırdığı gözlenmiştir [3].

Bu yarışmanın ilk kısmında, yani inme var/yok sınıflandırma probleminde model performansını arttırmak amacıyla transfer learning ve fine-tuning kullanılması düşünülmektedir. Özellikle ImageNet ile önceden eğitilmiş (pre-trained) modeller kullanılarak transfer learning uygulanması literatürde en sık rastlanan transfer learning yöntemidir. Bunun

temel sebebi, ImageNet veri setinin içinde bir milyondan daha fazla doğal resim bulundurması ve bu veri seti ile eğitilmiş çeşitli modellerin (örn: VGG, DenseNet, ResNet) oldukça güçlü özellik çıkarma (feature extraction) yeteneğine sahip olmasıdır.

İnme var/yok sınıflaması kapsamında, bu çalışmada sırasıyla VGG16, VGG19, DenseNet ve ResNet mimarileri ile deneysel çalışmalar gerçekleştirilecektir. Transfer learning gerçekleştirilirken kullanılması planlanan önceden eğitilmiş modelin hangi kısımlarının fine-tune edileceği ve/veya hangi hiper-parametreler kullanılacağı deneysel süreç gerçekleştirilmeden saptanması oldukça zor süreçlerden biridir. Literatürdeki beyin CT veya MR görüntüleri kullanılarak fine-tune edilen önceden ImageNet ile eğitilmiş modellerin performansı düşünüldüğünde şartnamede belirtilen duyarlılık ve özgüllük ortalaması minimum 0.75 isterinin sağlanacağı düşünülmektedir. Benzer şekilde alternatif metotlardan birisi de açık kaynaklı elde edilen benzer kaynaklı veri setleri kullanılarak (örn: MR görüntüleri üzerinden tümör tespiti) eğitilmiş modeller ile transfer learning gerçekleştirilebilir.

Yarışmanın ikinci kısmı, segmentasyon gerçekleştirmesi beklenen bir derin öğrenme modelidir. Literatürde segmentasyonu problemi için kullanılan mimariler genellikle convolutional encoder-decoder (CED) tabanlı modellerden oluşmaktadır. Burada temel amaç alınan girdi görüntülerini çeşitli konvolüsyonel filtrelerden geçirmek ve bu sayede girdi görüntüsü içerisinde istenilen segmentasyon görüntüsünü yeniden inşa etmeyi sağlayacak önemli özellikleri çıkarabilmektir. Bu işlem sırasında girdi görüntüleri belli bir boyuta kadar küçültülür ve kritik özelliklerin bulunduğu göreceli olarak küçük bir çözünürlükten istenilen çözünürlüğe ve segmentasyon karakterine doğru yeniden inşa edilir. Bu şekilde tasarlanan mimarilerin segmentasyon problemlerinde ciddi başarı sergilemektedir. İnme segmentasyon problemi için literatürde basit CED mimarileri çalışılmış ve başarılı sonuçlar alınabilmektedir. Örneğin 2017 yılında Chen vd. akut iskemik segmentasyonu için parça-çıkarmı (patch extraction) ve düzeltilmiş segmentasyon (refined segmentation) şeklinde iki adımlı bir segmentasyon modeli önermiş ve 0.83 oranında Dice skoru elde etmişlerdir [4]. Benzer şekilde başka bir çalışmada kanamalı inme problemi için üç boyutlu (3D) CNN tabanlı bir model önerilmiştir [5].

Biyomedikal veri setlerinin genellikle az veriden oluşmasından kaynaklı olarak çeşitli problemler ortaya çıkabilmektedir. Özellikle yüksek çözünürlükteki görüntüler söz konusu ise tanımlanan uzay yüksek boyuta (yüksek özellik) sahiptir. Bu durum over-fite sebep olabilmektedir. U-Net tipi mimarilerin düşük düzeydeki konvolüsyonel özellikleri yüksek düzeydeki özelliklerle beraber kullanmasının performansı ciddi anlamda arttırdığı gözlenmiştir [6]. U-Net tipi mimariler bu özelliklerinden dolayı literatürdeki birçok inme segmentasyonu



problemlerinde kullanılmıştır [7], [8]. Ayrıca modeller derinleştikçe kaybolan gradyanlar (vanishing gradient) problemi açığa çıkabilmektedir. Bu soruna çözüm olarak ResNet tipi konvolüsyonel bloklar inme segmentasyonu problemlerinde kullanılmış ve performansı arttırdığı gözlenmiştir [9]. Başka bir alternatif ise DenseNet tipi mimarilerin kullanımıdır. Bu tip mimariler de aynı şekilde kaybolan gradyanlar problemini çözmekle birlikte özellik çıkarımını güçlendirmektedir ve inme segmentasyon problemlerinde sıkça kullanılmaktadır [10]. İkinci aşama kapsamında uygulamayı planladığımız mimariler temel olarak U-Net, DenseNet ve ResNet tabanlı mimariler olarak tanımlanabilir. Bunlara ek olarak, genellikle segmentasyon problemlerinde sıkça kullanılan Cross-Entropy (CE) loss fonksiyonuna ek olarak, segmentasyon problemlerinde başarılı performans gösteren Focal loss ve Dice loss da incelenecektir.

### **2.1.2 Problemde kullanılacak veri setleri**

Birinci aşama (sınıflandırma) problemi için açık kaynak veri setleri araştırıldığında inme problemine uygun veri seti bulunamamıştır. Elde edilen veri setlerinden birisi “Brain Tumor Classification (MRI)” [11] veri setidir. Bu veri seti toplam dört sınıfa ait beyin CT görüntülerinden oluşmaktadır. Bu sınıflar tümörsüz, glioma tümör, meningioma tümör ve pituitary tümör olarak tanımlanmıştır. Eğitim veri seti içerisinde tümörsüz 395, glioma tümörlü 826, meningioma tümörlü 822 ve pituitary tümörlü 827 olmak üzere toplam 2870 CT görüntüsü bulundurmaktadır. Benzer şekilde test veri seti içerisinde de tümörsüz 105, glioma tümörlü 100, meningioma tümörlü 115 ve pituitary tümörlü 74 olmak üzere toplam 684 CT görüntüsü bulundurmaktadır. Bu veri seti, beyin CT görüntülerinden oluştuğu için inme görüntülerine benzer bir dağılımdan geleceğinden transfer learning için kullanılabilir kaynak veri seti olarak düşünülmektedir. Benzer şekilde, “Brain CT Hemorrhage Dataset” [12] isimli veri setinde de sınıflandırma probleminde transfer learning için kaynak veri seti olarak kullanılması planlanan kanamalı ve kanamalı olmayan hastalardan alınan beyin CT görüntüleri bulunmaktadır.

İkinci aşama (segmentasyon) problemi için ise kullanılması planlanan veri setlerinden birisi, “USC Stevens Neuroimaging and Informatics Institute” tarafından izinle alınan “Anatomical Tracings of Lesions After Stroke (ATLAS [13])” veri setidir. Bu veri seti içerisinde toplam 229 adet inme görüntüsü ve segmente edilmiş hedef görüntüleri bulundurmaktadır. Kullanılması düşünülen son veri seti ise “Brain CT Images with Intracranial Hemorrhage Masks” [14] veri setidir. Bu veri seti içerisinde beyinde kanama olan bölgeler için, 82 farklı hastadan alınmış toplamda 2500 beyin CT görüntüleri, segmente edilmiş bölgeleri ile birlikte bulunmaktadır.

### **2.1.3 Model performans testleri için gerçekleştirilecek deneysel süreçler ve kullanılacak metrikler**

Model performans testleri için gerçekleştirilecek olan deneyler arasında çeşitli loss fonksiyonları ve model mimarileri bulunmaktadır. Sınıflandırma problemi için düşünülen en uygun loss fonksiyonu CE olup transfer learning gerçekleştirilecek olan veri setleri (ImageNet veya açık kaynaklı elde edilen kanser veya inme veri setleri) ve model mimarileri (VGG, DenseNet, ResNet ) deneysel sürece tabii tutulacaktır. Transfer learning için fine-tune işleminin transfer edilen modelin hangi bölümünden başlayacağı da deneysel süreçlere dahildir. Ayrıca deneysel süreçler arasında hiper-parametre optimizasyonu da bulunmaktadır ve Grid-Search gibi optimize parametreleri bulma yöntemleri kullanılabilir. Segmentasyon problemi kısmı için ise U-Net tabanlı bir derin öğrenme modeli kullanılması kararlaştırılmıştır. Deneysel süreç içerisinde özellikle model derinliği ve CE'ye ek olarak loss fonksiyonları üzerine deneysel çalışmalar yapılacaktır İlk kısma benzer şekilde 2.1.2'de bahsedilen veri setleri üzerinden de transfer learning kullanılması ve sonuçların incelenmesi de deneysel süreçler içerisinde.


Sınıflandırma probleminde incelenecek metrikler sırasıyla doğruluk (Accuracy), kesinlik (Precision), duyarlılık (Recall) ve özgüllük (False Positive Rate) olarak tanımlanabilir. Doğruluk metriği genellikle sınıflandırma problemlerinde kullanılan en temel metriktir. Doğru tahminlerin tüm tahminlere oranı olarak tanımlanır. Kesinlik metriği pozitif tahminlerin gerçekten kaçının pozitif olduğunu gösteren bir metriktir. Duyarlılık metriği pozitif olarak elde edilmesi gereken tahminlerin gerçekten ne kadarının pozitif tahmin edildiğini ölçen bir metriktir. Özgüllük değeri ise tüm negatif veri noktalarına göre yanlış pozitif olarak kabul edilen negatif veri noktalarının oranına karşılık gelmektedir. Bu kısımda şartname isteri olan özgüllük ve duyarlılık ortalamasının minimum 0.75 olan isterini sağlamak amacıyla bu metrik odak noktası olarak seçilecektir.

Segmentasyon kısmı için ise incelenecek temel metrik IoU (Intersection over Union) metriğidir. IoU metriği ikinci kısım kapsamında tahmin ve gerçek segmente görüntülerin kesişimindeki 0'dan farklı piksellerin sayısının şartnamede belirtilen MASK\_P ve MASK\_E görüntülerinin birleşimindeki 0'dan farklı piksellerin sayısına oranının yüzdesel gösterimi olarak tanımlanmıştır. Kesişim hesaplanırken her iki görüntüdeki 1 ve 2 sınıflarına ait pikseller hesaba katılacak olup, birleşim kümesinde ise her iki resimde de 0'dan farklı bulunan pikseller hesaba katılacaktır.

## **2.2 Yazılım Çözümü**

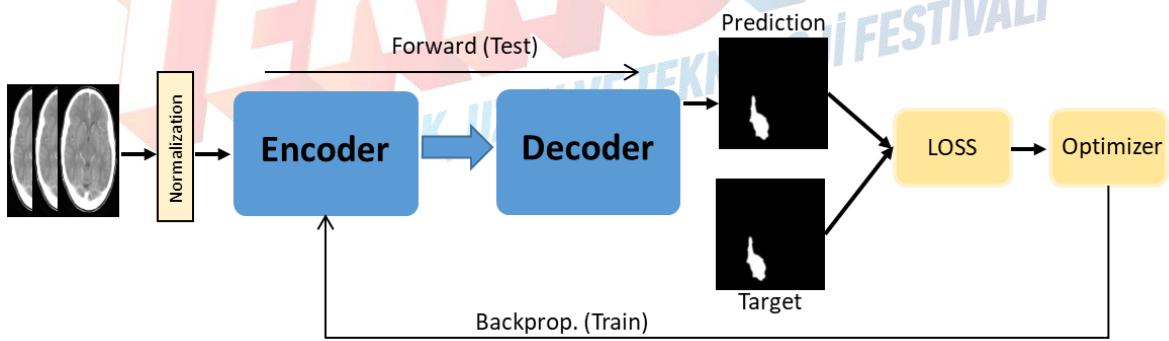
### **2.2.1 Makine öğrenimi modelinin eğitim, test ve kullanım süreçlerine önerilen ait kullanım-usecase-çizeneği**

Birinci aşama olan sınıflandırma problemi için önerilen derin CNN tabanlı derin öğrenme modelinin eğitim ve test süreçlerini gösteren kullanım çizeniği Şekil. 2’de paylaşılmıştır.



Şekil. 2 Sınıflandırma problemi için kullanım çizeniği

Şekil. 2’de görüleceği üzere CNN tabanlı bir derin öğrenme modeli kullanılacaktır. Amaç CT verilerini kullanarak inme var/yok ikili sınıflandırmasını başarılı bir şekilde gerçekleştirmektir. Eğitim kısmı için şekilde görülen Backpropagation ile loss değerine göre kısmi türevlere bağlı olarak gradyanlar elde edilecek ve model ağırlıkları güncellenecektir. Test kısmında ise ileriye beslemeli olarak (ağırlıklar güncellenmeden) doğrudan eğitim sırasında elde edilmiş ağırlıklara bağlı olarak tahminler elde edilir. İkinci aşama olan segmentasyon problemi için önerilen derin Encoder-Decoder tabanlı derin öğrenme modelinin eğitim ve test süreçlerini gösteren kullanım çizeniği Şekil. 3’te paylaşılmıştır.



Şekil. 3 Segmentasyon problemi için kullanım çizeniği

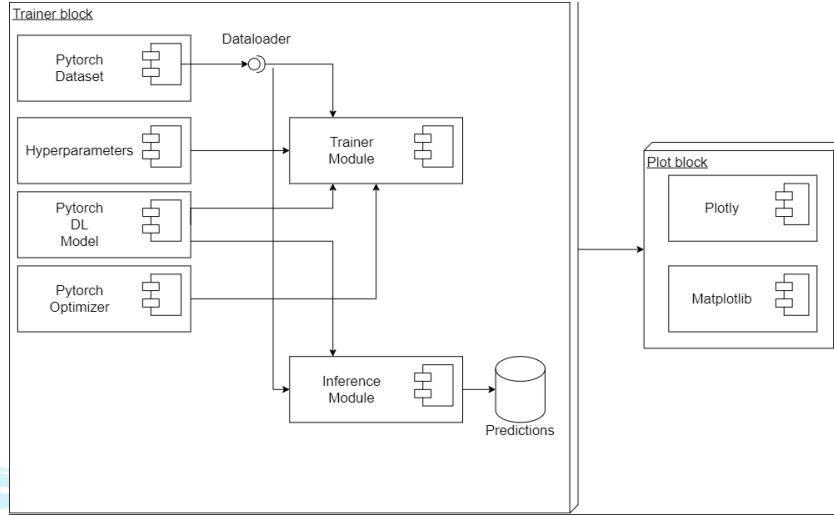
Şekil. 3’te görüleceği üzere ikinci aşama olan segmentasyon kısmı için önerilen model Encoder-Decoder tabanlı bir mimari olacaktır. Amaç CT görüntülerini kullanarak inmenin tipine ve görüntü içinde bulunduğu konuma göre segmente edilmiş görüntüyü yeniden inşa etmektir. Yeniden inşa edilen segmente görüntüsü üzerinde inme bulunmayan pikseller 0



değerini, iki tip inmeye göre ise 1 veya 2 değerini alacaktır. Eğitim ve test kısımları sınıflandırma problemi için yukarıda anlatılan çerçevede gelişecektir.

### 2.2.2 Kullanılan teknolojileri içeren yazılım bileşen-component- çizeneği

Kullanılan teknolojileri içeren yazılım-bileşen çizeneği Şekil. 4'te paylaşılmıştır.



Şekil. 4 Yazılım-bileşen çizeneği

Şekil. 4'te görülebileceği üzere Veri setinin işlenmesi, derin öğrenme modellerinin eğitilmesi ve testlerin gerçekleştirilmesinde Python yazılım diline Pytorch kütüphanesi kullanılacaktır. Görselleştirmeler için ise Matplotlib ve Plotly kütüphaneleri kullanılacaktır.

## 3. Kullanılması planlanan algoritmalar ve yazılım mimarisi

### 3.1 Eğitim Donanımları

Eğitimler için 64 bit işletim sisteminde 3.30 GHz Intel(R) Xeon(R) W-2155 CPU işlemcili bir sistem kullanılacaktır. Sistemin yüklü belleği (RAM) 128 GB olarak kullanılacaktır. RAM değerinin yüksek olması veri setinin yazılım platformuna yüklenebilmesi ve işlenebilmesi için oldukça önem taşımaktadır. Özellikle açık kaynaklı veri setleri kullanılacağından ve CT görüntüleri yüksek çözünürlükte olabileceğinden yüksek bellek oldukça kritiktir. Derin öğrenme modelleri eğitilirken Grafik İşlemci Ünitesi (GPU) kullanılması neredeyse zorunluluktur. Özellikle hız açısından GPU kullanımı ciddi avantaj sağlamaktadır. Bu sebeple model eğitiminde yüksek hızda eğitim sağlayabilen CUDA destekli iki adet GDDR6 12 GB NVIDIA GeForce RTX 3060 ekran kartı kullanılacaktır. Derin öğrenme modelleri eğitilirken parti boyutu (Batch size) oldukça önemli bir parametre olmakla birlikte küçüldükçe eğitim performansında sorunlar ortaya çıkabilmektedir. CT görüntülerinin çözünürlüklerinin yüksek olduğu düşünüldüğünde, 12 GB hafızalı iki adet ekran kartı kullanılması, eğitimlerde parti boyutunun eğitim performansını düşürmeden seçilebilmesini sağlamaktadır. Örneğin görüntü

çözünürlüğünün  $512 \times 512$  olduğu durumda ve ImageNet ile eğitilmiş bir modelden transfer learning yapıldığı düşünüldüğünde Pytorch için girdi boyutu (parti boyutu  $\times 3 \times 512 \times 512$ ) olacaktır. Yaptığımız hesaplara göre bu girdi boyutlarında 2 adet 12 GB belirtilen ekran kartının kullanılması, 10 değerindeki parti boyutunun kullanılmasına izin verecektir. Bu parti boyutu hiper-parametreler doğru seçildiği takdirde (örn: öğrenme oranı, normalizasyon yöntemi vs) yüksek performansta eğitim sağlayabilecektir.

### 3.2 Test Donanımları

Test kısımları için de aynı donanımlar kullanılacaktır. Eğitimden farklı olarak sadece, test için eğitim gerekmediğinden, bir ekran kartının kullanılması yeterli olacaktır.

## 4. Özgünlük

Sınıflandırma problemi için literatürde önerilmiş güçlü mimariler (VGG, ResNet, DenseNet) deneysel olarak incelenecektir. Eğitimler için standart CE loss kullanılacaktır. ImageNet veya açık kaynaklı elde edilen veri setleri ile eğitilmiş modeller Teknofest tarafından verilecek olan veri seti için fine-tune edilecektir. Sınıflandırma problemleri literatürde oldukça fazla çalışılmış olup, yukarıda bahsedilen standart mimarilerin kullanımı en yaygın yaklaşımdır. Buna ek olarak model iyileştirilmeleri için çeşitli fine-tune teknikleri (örn: modelin hangi kısmından itibaren fine-tune edileceği) kullanarak deneysel çalışma gerçekleştirilecektir. Bu aşamada özgün olarak ilk adımda ImageNet veri seti ile önceden eğitilmiş bir modeli, açık kaynak ve inme veri setine yakın bir veri seti (örn: kanser sınıflandırma veri seti) ile fine-tune etmek ve ikinci adımda aynı modeli Teknofest tarafından verilen ikinci bir veri seti ile tekrar fine-tune etmek şeklinde iki adımlı bir transfer learning metodu deneysel olarak incelenecektir. Segmentasyon problemi için ise benzer bir transfer learning metodu kullanılabilir. Sınıflandırma probleminden farklı olarak ise amaç boyutu düşürülmüş uzaydan decoder kullanarak segmente edilmiş görüntünün yeniden inşa edilmesidir. Bunu yapabilmek için ilgili modelin fully connected layer'ları çıkarılmalı ve yerine segmente görüntüyü inşa edecek konvolüsyonel katmanlar (Decoder) yerleştirilmelidir. Bu durumda ilgili modelin konvolüsyonel katmanları transfer edilerek segmentasyon için Encoder kısmı olarak değerlendirilebilir. Ayrıca Ates ve Gorguluarslan [15] tarafından görüntü segmentasyon performansını arttırmak için önerilen iki adımlı bir Encoder-Decoder mimarisi düşünülecektir. Mimari kısmına ek olarak ise segmentasyon model performanslarını arttırdığı gözlenen Atrous Convoluton ve Spatial Pyramid Pooling gibi gelişmiş teknikler de kullanılacaktır. Bunlara ek olarak segmentasyon problemlerinde en çok kullanılan Focal Loss ve Dice Loss'a ek olarak, biyomedikal segmentasyonda daha önce hiç kullanılmamış olan ve

doğrudan iki resmin benzerliğini kontrast ve luminans değerleri ile ölçen Structural Similarity Loss (SSIM) da model performansını arttırmak amacıyla kullanılacaktır.

## 5. Proje Takvimi

Ön tasarım raporu tesliminden, kritik ve ön bulgu raporu teslimine kadar olan süre aralığındaki projenin ilerleyişindeki kilometre taşları tarihleri ile birlikte Şekil. 5'te paylaşılmıştır.



Şekil. 5 Proje takvimi

## 6. Referanslar

- [1] N. Abiwinanda, M. Hanif, S. T. Hesaputra, A. Handayani, and T. R. Mengko, "Brain tumor classification using convolutional neural network," in *IFMBE Proceedings*, 2019, vol. 68, no. 1, pp. 183–189, doi: 10.1007/978-981-10-9035-6\_33.
- [2] J. S. Paul, A. J. Plassard, B. A. Landman, and D. Fabbri, "Deep learning for brain tumor classification," in *Medical Imaging 2017: Biomedical Applications in Molecular, Structural, and Functional Imaging*, Mar. 2017, vol. 10137, p. 1013710, doi: 10.1117/12.2254195.
- [3] Z. N. K. Swati *et al.*, "Brain tumor classification for MR images using transfer learning and fine-tuning," *Comput. Med. Imaging Graph.*, vol. 75, pp. 34–46, Jul. 2019, doi: 10.1016/j.compmedimag.2019.05.001.
- [4] L. Chen, P. Bentley, and D. Rueckert, "Fully automatic acute ischemic lesion segmentation in DWI using convolutional neural networks," *NeuroImage Clin.*, vol. 15, pp. 633–643, 2017, doi: 10.1016/j.nicl.2017.06.016.

- [5] Y. Wang, L. Heng, Y. Liu, and W. Liu, "Deep learning framework for hemorrhagic stroke segmentation and detection," in *BIBE 2018; International Conference on Biological Information and Biomedical Engineering*, 2018, pp. 1–6.
- [6] O. Ronneberger, P. Fischer, and T. Brox, "U-net: Convolutional networks for biomedical image segmentation," in *International Conference on Medical image computing and computer-assisted intervention*, 2015, pp. 234–241.
- [7] H. Kuang, B. K. Menon, and W. Qiu, "Segmenting Hemorrhagic and Ischemic Infarct Simultaneously from Follow-Up Non-Contrast CT Images in Patients with Acute Ischemic Stroke," *IEEE Access*, vol. 7, pp. 39842–39851, 2019, doi: 10.1109/ACCESS.2019.2906605.
- [8] W. Qiu *et al.*, "Machine Learning for Detecting Early Infarction in Acute Stroke with Non-Contrast-enhanced CT," *Radiology*, vol. 294, no. 3, pp. 638–644, Mar. 2020, doi: 10.1148/radiol.2020191193.
- [9] Z. Liu, C. Cao, S. Ding, Z. Liu, T. Han, and S. Liu, "Towards clinical diagnosis: Automated stroke lesion segmentation on multi-spectral MR image using convolutional neural network," *IEEE Access*, vol. 6, pp. 5706–57016, 2018, doi: 10.1109/ACCESS.2018.2872939.
- [10] X. Li, H. Chen, X. Qi, Q. Dou, C. W. Fu, and P. A. Heng, "H-DenseUNet: Hybrid Densely Connected UNet for Liver and Tumor Segmentation from CT Volumes," *IEEE Trans. Med. Imaging*, vol. 37, no. 12, pp. 2663–2674, Dec. 2018, doi: 10.1109/TMI.2018.2845918.
- [11] "Brain Tumor Classification (MRI) | Kaggle." <https://www.kaggle.com/sartajbhuvaji/brain-tumor-classification-mri> (accessed Apr. 14, 2021).
- [12] "Brain CT Hemorrhage Dataset | Kaggle." <https://www.kaggle.com/abdulkader90/brain-ct-hemorrhage-dataset> (accessed Apr. 14, 2021).
- [13] S. L. Liew *et al.*, "A large, open source dataset of stroke anatomical brain images and manual lesion segmentations," *Sci. Data*, vol. 5, no. 1, pp. 1–11, Feb. 2018, doi: 10.1038/sdata.2018.11.
- [14] "Brain CT Images with Intracranial Hemorrhage Masks | Kaggle." <https://www.kaggle.com/vbookshelf/computed-tomography-ct-images> (accessed Apr. 14, 2021).
- [15] G. C. Ates and R. M. Gorguluarslan, "Two-stage convolutional encoder-decoder network to improve the performance and reliability of deep learning models for topology optimization," *Struct. Multidiscip. Optim.*, vol. 63, pp. 1927–1950, 2021, doi: 10.1007/s00158-020-02788-w.